Universität Münster

Statistische Analyse cluster-korrelierter Daten

5. Mai 2026, DGoEV Jahrestagung

Univ.-Prof. Dr. Sebastian-Edgar Baumeister

Universität Münster

Übersicht

- Einleitung & Fragestellungen
- Was sind cluster-korrelierte Daten?
- Weshalb erfordern sie spezielle Verfahren?
- Statistische Methoden: Mixed Models, GEE, Bootstrap
- Die Rolle der Clusteranzahl
- Anwendung auf simulierte Daten
- Interpretation der Schätzer: konditional vs. marginal
- Kausale Inferenz bei cluster-korrelierten Daten

Motivation

Warum dieses Thema?

In der oralen Epidemiologie und Versorgungsforschung sind Daten häufig cluster-korreliert

Clusterebene	Beispiel
Zähne in Patienten	PPD-Messungen an 28 Zähnen
Taschen an Zähnen	Mehrere Messungen pro Zahn
Patienten in Praxen	Praxisbasierte Studien
Wiederholte Messungen	Kohorten

Leitfragen

Drei Leitfragen für diesen Impuls

1. Bias vs. Precision

Ignorieren von Clusterung → verzerrte *Standardfehler* (nicht die Punktschätzer selbst!) → Zu enge Konfidenzintervalle, zu kleine p-Werte

2. Konditional vs. Marginal

Mixed Models und GEE beantworten *unterschiedliche Fragen* → Wann welches Effektmaß?

3. Kausalität

Clusterung hat Implikationen für kausale Identifikation → Welche Annahmen müssen gelten?

Was sind cluster-korrelierte Daten?

Beobachtungen sind cluster-korreliert, wenn Einheiten innerhalb eines Clusters einander ähnlicher sind als Einheiten aus anderen Clustern.

$Cor(Y_{ij}, Y_{ik}) > 0$ für j ≠ k innerhalb Cluster i

wobei:
i = Cluster (z.B. Patient)
i,k = Beobachtungen im Cluster (z.B. Zähne)

Intraklassenkorrelation (ICC):

$$\rho = \frac{\sigma^2_{Cluster}}{\sigma^2_{Cluster} + \sigma^2_{Residual}}$$

→ICC = 0: keine Korrelation innerhalb Cluster

→ICC = 1: perfekte Korrelation

Was sind cluster-korrelierte Daten?

Ebene 3: Zahnarztpraxis (g = 10–100 Praxen)

|

Ebene 2: Patient (n_j = 5–1000 pro Praxis)

|

Ebene 1: Zahn × Zeitpunkt (28 Zähne × T Messungen)

Varianzzerlegung:

$$\sigma^2_{Gesamt} = \sigma^2_{Praxis} + \sigma^2_{Patient} + \sigma^2_{Zahn} + \sigma^2_{Residual}$$

Typische ICCs in der Parodontologie:

Clusterebene	PDD
Praxis	0.02 – 0.08
Patient	0.15 – 0.40
Zahn	0.05 – 0.15

Quellen für Clusterung

Warum entsteht Clusterung in der oralen Epidemiologie und Versorgungsforschung

Biologisch:

- Genetische Disposition → alle Zähne eines Patienten betroffen
- Patientenbezogene Risikofaktoren (Rauchen, Diabetes, Immunsuppression) → Patientenebene
- Lokale Faktoren (Okklusion, Anatonie) → Zahnebene

Studiendesign:

- Longitudinale Messwiederholungen → serielle Korrelation
- Multizentrische Studien → Praxiseffekte (Diagnostik, Therapie)
- Cluster-randomisierte Studien → Randomisierung auf Praxenebene

Kreuzklassifikation:

- Zahn × Zeitpunkt (zwei gekreuzte Cluster innerhalb Patient)
- Patient × Praxis (bei Praxiswechsel)

Weshalb spezielle Verfahren?

Der Design-Effekt (DEFF)

$$DEFF = 1 + (\overline{m} - 1) \times ICC$$

wobei $\overline{m}$ = mittlere Clustergröße

Zahlenbeispiel:

$\overline{m}\ (\frac{Zähne}{Patient})$	ICC	DEFF	SE-Inflation (√DEFF)
28	0.05	2.35	1.53 ×
28	0.15	5.05	2.25 ×
28	0.30	9.10	3.02 ×

Konsequenz:

- Bei ICC = 0.15 ist der naive SE um Faktor 2.25 zu klein
- 95%-KI ist in Wirklichkeit doppelt so breit
- p-Werte sind dramatisch zu klein

Weshalb spezielle Verfahren?

Effektive Stichprobengröße:

$$n_{eff} = \frac{n}{DEFF}$$

Beispiel: 1.500 Patienten × 28 Zähne = 42.000 Beobachtungen

→ Bei DEFF = 5: $n_{eff} \approx 8.400$ *unabhängige* Beobachtungen

Weshalb spezielle Verfahren?

Drei Konsequenzen ignorierter Clusterung

1. Standardfehler zu klein

Typ-I-Fehler-Inflation

95%-KI hat tatsächliche Überdeckung von z. B. 70%

„Signifikante" Befunde, die keine sind

2. Modell-Inferenz ungültig

Likelihood-Ratio-Tests, AIC/BIC: falsch

Modellvergleiche nicht verlässlich

3. Effizienzeinbußen

Ungenutzte Information über die Korrelationsstruktur

Besonders bei unbalancierten Clustern: Mixed Models effizienter

Wichtig: Die *Punktschätzer* (β) bleiben unter milden Bedingungen erwartungstreu – das Problem sind die **Standardfehler** und damit die **Inferenz**.

Übersicht über Verfahren

Drei Auswertungsstrategien im Vergleich

	Mixed Models	GEE / Cluster-robust SE	Wild Cluster Bootstrap
Modellierung	Explizite Random Effects	Working Correlation	Resamplingbasiert
Effektmaß	Konditional (subjektspezifisch)	Marginal (populationsgemittelt)	Je nach Basismodell
SE-Korrektur	Modellbasiert	Sandwich-Schätzer	Empirisch
Kleine Cluster-N	Gut bei $g \geq 20$	Problematisch bei $g < 30$	Gut bei $g \geq 10$
Software	R: lme4, glmmTBM; Stata: meglm, mixed	R: gee, geepack; Stata: xtgee, vce(cluster)	R: boot, fwildclusterboo, wildboottestjlr; Stata: bootstrap, boottest

Mixed Models

Grundidee

Mixed Models erlegen die Gesamtvarianz in feste und zufällige Effekte:

$$g\left(E\left[Y_{ij}|X, b_i\right]\right) = X_{ij}\beta + Z_{ij}b_i$$

β = feste Effekte (Populationsparameter)

b_i = zufällige Effekte ~ N(0,D)

→ Clusterspezifische Abweichungen vom Populationsmittel

g(.) = Link-Funktion (log, logit,…)

In unserem Beispiel (Gamma, log-link):

$$\log\left(E\left[PPD_{ijk}|X, b\right]\right) = \beta_1 car_{new} + \beta_2 age + \cdots + u_{Praxis} + u_{Patient}$$

u ~ N(0, σ^2_{Praxis})

v ~ N(0, $\sigma^2_{Patient}$)

$\boldsymbol{\beta_1}$ **= konditionaler Effekt** = Effekt *bei gleichem* Random Effect

Mixed Models

Interpretation des konditionalen Effekts

$\exp(\beta_1)$ im Gamma-GLMM mit Log-Link:

„Für einen bestimmten Patienten in einer bestimmten Praxis ist die erwartete PPD bei neuer Karies um den Faktor $\exp(\beta_1)$ höher als ohne Karies.“

Vorteile:

- Natürliche Modellierung der Clusterstruktur
- ICC als Nebenprodukt
- Prädiktion auf Subjektebene möglich
- Effizient bei unbalancierten Daten

Nachteile:

- Verteilungsannahmen für Random Effects (Normalität)
- Rechenintensiv bei drei+ Ebenen und GLMMs
- Konditionaler Effekt ≠ Populationseffekt (bei nichtlinearen Links)

Mixed Models

R-Implementierung

```
library(glmmTMB)
fit_gamma <- glmmTMB(
  ppd ~ car_new + age + smk_c + diabetes + molar +
    (1 | practice_id) +   (1 | practice_id:patient_id),   data   = df,   family = Gamma(link = "log"))
icc(fit_gamma)
```

Stata-Implementierung

```
meglm ppd car_new c.age smk_c diabetes molar || practice_id:   || patient_id: ,  family(gamma) link(log)
estat icc
```

Mixed Models

Konvergenzprobleme bei GLMMs:

Laplace-Approximation statt Gauss-Hermite

Fallback: log-transformiertes lineares Mixed Model

GEE und Cluster-robuster SE

Generalized Estimating Equations (GEE)

Grundidee: Schätze den *marginalen* (populationsgemittelten) Effekt, ohne die Random-Effects-Verteilung zu spezifizieren.

Zwei Bausteine:

1. Arbeitende Korrelationsstruktur (working correlation):

- Exchangeable: $Cor\left(Y_{ij}, Y_{ik}\right)$ = α für alle j ≠ k
- AR(1): $Cor\left(Y_{ij}, Y_{i,j+1}\right) =$ α^|j-k| (longitudinal)
- Unstructured: alle Korrelationen frei

2. Sandwich-Schätzer (robust SE):

$$\widehat{\mathrm{Var}}\left(\hat{\beta}\right) = B^{-1}\left(\sum_{i=1}^{g} \hat{e}_i\, \hat{e}_i'\right) B^{-1}$$

→Konsistente SE *unabhängig* davon, ob die Arbeitskorrelation korrekt ist

→ Daher „robust"

GEE und Cluster-rubuster SE

Generalized Estimating Equations (GEE)

Marginaler Effekt – Interpretation

$\exp(\beta_1)$ im GEE (Gamma, log-link):

„In der Population ist die erwartete PPD bei Zähnen mit neuer Karies um den Faktor $\exp(\beta_1)$ höher – gemittelt über alle Patienten und Praxen."

→ Gleicher Punktschätzer wie naives GLM → Nur die SE werden korrigiert → Clusterebene muss korrekt gewählt werden!

Zwei-Wege-Clusterung:

Was, wenn auf *beiden* Ebenen geclustert werden muss?

→ vce(cluster practice_id) konservativer (höhere Ebene)

→ Multi-way clustering (Cameron, Gelbach, Miller 2011)

Wild Cluster Bootstrap

Motivation

Sandwich-SE bei **wenigen Clustern (g < 30–50)** nach unten verzerrt:

- Asymptotische Theorie gilt für g → ∞
- Bei g = 10–15 Praxen: erhebliche Verzerrung

Wild Cluster Bootstrap (Cameron, Gelbach, Miller 2008):

Algorithmus:

1. Schätze Modell → Residuen $\hat{e}_{ij}$
2. Für b = 1, …, B: a. Ziehe Rademacher-Gewichte $w_i \in \{-1, +1\}$ pro *Cluster*
   b. Bilde $Y_{ij} = \hat{X}_{ij}\beta\hat{} + w_i \cdot \hat{e}_{ij}$ *c. Schätze Modell mit Y* → t*-Statistik
3. p-Wert: Anteil |t*| ≥ |t_beobachtet|

Vorteil: Funktioniert bei wenigen Clustern (g ≥ 6–10)

Nachteil: Nur Hypothesentests, keine direkten KIs

Cluster Bootstrap (Praxenebene)

Klassischer Cluster-Bootstrap

- Alternative bei wenigen Praxen:
- Resample *ganze Praxen* mit Zurücklegen
- Innerhalb jeder Praxis: alle Patienten und Zähne bleiben intakt

Vergleich der Bootstrap-Varianten:

	Pairs Cluster Bootstrap	Wild Cluster Bootstrap
Resamplingeinheit	Ganze Cluster	Residuen-Vorzeichen
Asymptotik	$g \to \infty$	$g \to \infty$, aber schneller
KIs	Direkt (Perzentile)	Nur p-Werte (ohne Erweiterung)
Empfehlung g	≥ 20	≥ 6–10
Resamplingeinheit	Ganze Cluster	Residuen-Vorzeichen

Rolle der Clusterzahl

Wie viele Cluster brauchen wir?

Für Sandwich-Schätzer (GEE/cluster-robust SE):

g(Cluster)	Bias des Sandwich-SE	Empfehlung
< 10	Stark nach unten verzerrt	⚠ Nicht verwenden
10–29	Moderate Verzerrung	Wild Cluster Bootstrap
30–49	Leichte Verzerrung	Akzeptabel mit Korrekturen
≥ 50	Vernachlässigbar	Zuverlässig

Korrekturen bei moderatem g:

- Kleine-Stichproben-Korrektur: multipliziere SE mit $\sqrt{(g/(g-p))}$
- Satterthwaite/Kenward-Roger: reduzierte Freiheitsgrade
- CR2/CR3-Varianzschätzer (MacKinnon & Webb 2017)

Rolle der Clusterzahl

Effizienz und Information

Mixed Models: Information kommt aus *zwei Quellen*:

1. Between-Cluster-Variation (zwischen Praxen/Patienten)
2. Within-Cluster-Variation (innerhalb)

Effektiver Beitrag eines neuen Clusters vs. einer neuen Beobachtung im Cluster:

Bei hohem ICC:

- Ein *neuer Patient* bringt mehr Information als ein *zusätzlicher Zahn*
- Ein *neue Praxis* bringt mehr Information als ein *zusätzlicher Patient*

Faustformel für Power:

$$n_{eff} \approx \frac{g \cdot m}{1 + (m - 1) \cdot ICC}$$

→Bei ICC = 0.20 und m = 28 Zähnen: 28 Zähne ≈ **4.4 unabhängige** Beobachtungen pro Patient

→ Investiere in *mehr Cluster*, nicht in *größere Cluster*!

Simulationsstudie: Design

Simulierter Datensatz: Karies → Parodontitis

Datengenerierende Struktur:

- Drei-Ebenen-Clusterung: Praxis → Patient → Zahn × Zeit
- Zu Beginn: keine Karies, keine Parodontitis
- Diskretes Überlebensmodell für Karies-Onset
- PPD/CAL: Gamma-verteilt, beeinflusst durch Karies
- Zahnverlust: diskretes Hazard-Modell

Wahre Parameter (bekannt):

- β(Karies → PPD) = 0.60 mm (Identitäts-Skala)
- σ_Praxis = 0.40, σ_Patient = 0.70, σ_Zahn = 0.30

Systematisch variiert:

Dimension	Werte
Zahnarztpraxen	10, 20, 30, 50, 100
Patienten / Praxis	5, 10, 20, 50, 100, 200, 500, 1000
Messwiederholungen	2, 3, 5, 8, 10

→ 16 Szenarien, Basisszenario: 30 Praxen, 50 Pat./Praxis, 5 ZP

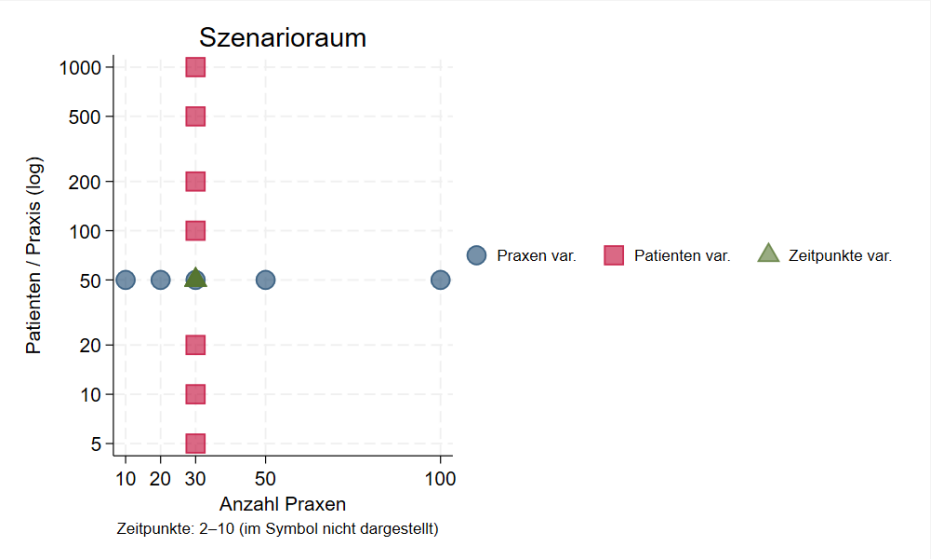

Simulationsstudie: Szenarien

Datensatzgrößen nach Szenario

Szenario	Praxen	Pat./Praxis	ZP	N Beobachtungen
Wenige Praxen	10	50	5	70.000
Basis	**30**	**50**	**5**	**210.000**
Viele Praxen	100	50	5	700.000
Kleine Cluster	30	5	5	21.000
Große Cluster	30	1000	5	4.200.000
Wenige ZP	30	50	2	84.000
Viele ZP	30	50	10	420.000

Exposition: car_new (neue Karies, zahnspezifisch)

Outcome: PPD (Probing Pocket Depth)

Simulationsstudie: Szenarien

Datensatzgrößen nach Szenario

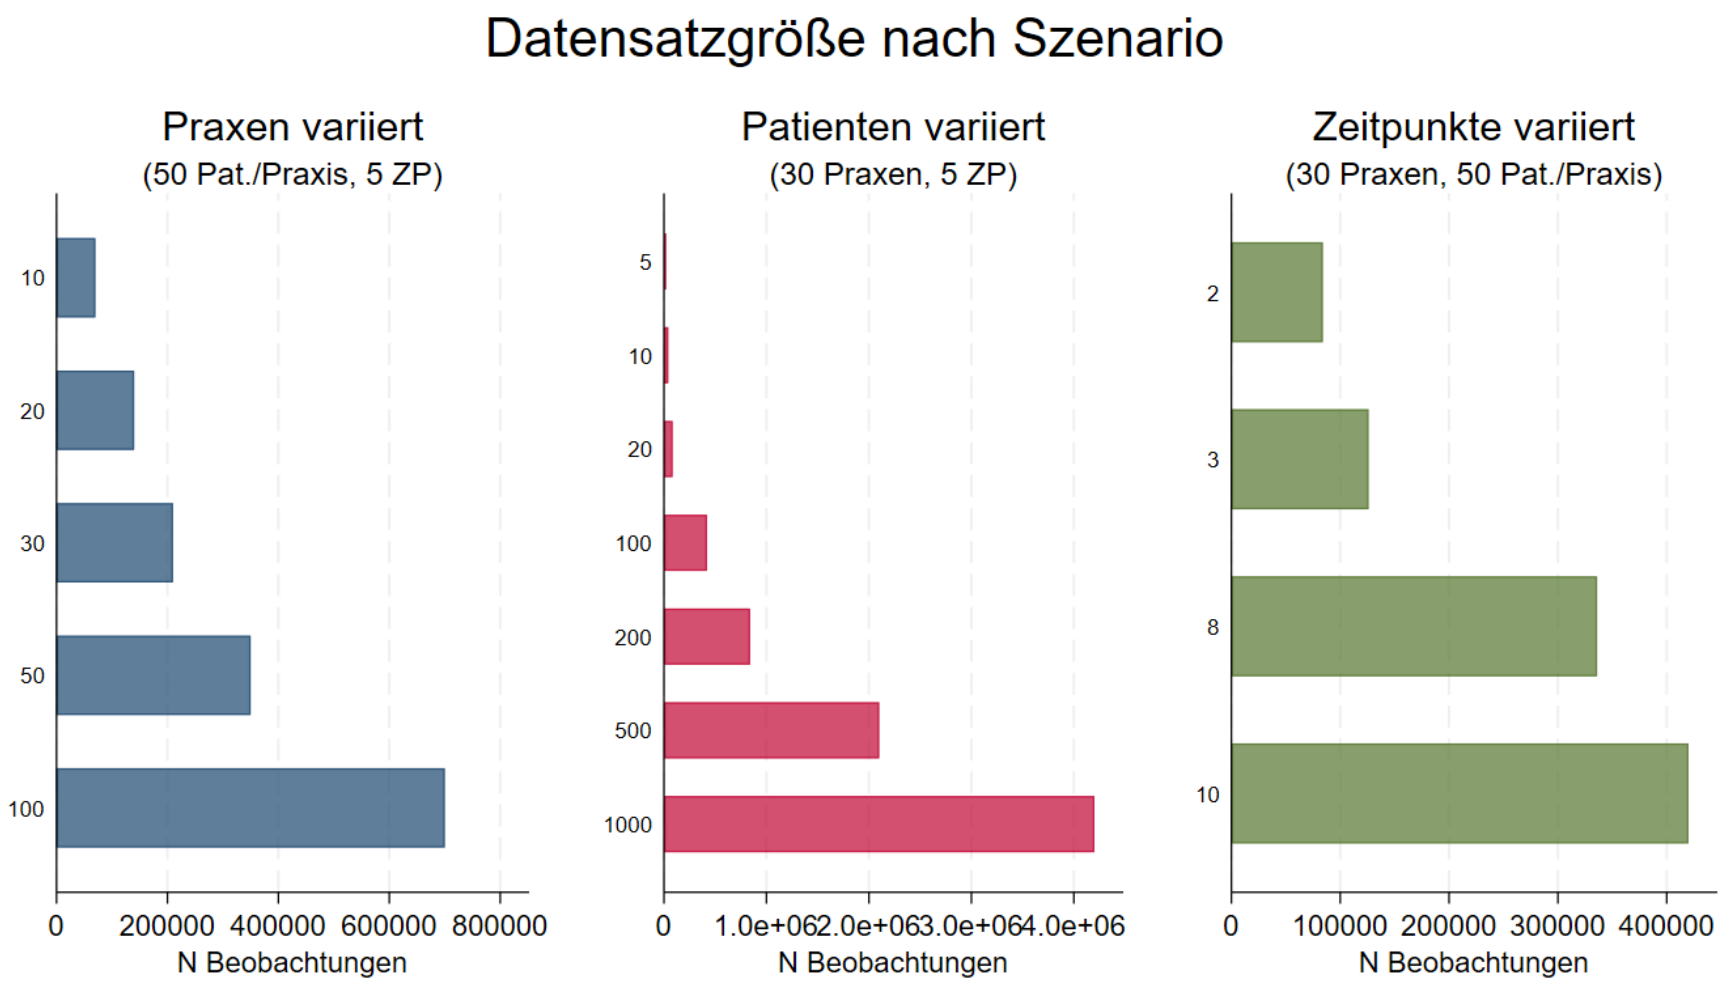

28 Zähne pro Patient

Ergebnisse: SE-Inflation

SE-Verhältnis (Methode / Naiv) nach Clustergröße

Zentrale Befunde:

	Pat./Praxis			
	5	**50**	**200**	**1000**
Cluster-Pat.	1.3	2.1	3.4	5.8
Cluster-Prax.	1.5	2.5	4.1	7.2
Mixed Model	1.4	2.3	3.8	6.5
GEE (robust)	1.3	2.2	3.6	6.1
Bootstrap	1.6	2.6	4.3	7.5

→ *Alle* Methoden zeigen SE > naives Modell

→ Inflation wächst mit Clustergröße (mehr Pat./Praxis)

→ Bootstrap am konservativsten (gut bei wenigen Praxen)

Ergebnisse: Gamma-GLM, log-link

exp(β) für car_new → PPD: Basisszenario

	exp(β)	95%-KI
Naiv (Clusterung ignoriert)	1.052	[1.038, 1.066]
Cluster-Pat.	1.052	[1.021, 1.084]
Cluster-Prax.	1.052	[1.014, 1.092]
Mixed Model	1.058	[1.022, 1.096]
GEE (exchangeable)	1.053	[1.020, 1.087]
Bootstrap	1.052	[1.011, 1.097]

→ Punktschätzer nahezu identisch (bei log-link!)

→ KI-Breite variiert um Faktor 2–3

→ Mixed Model: leicht höherer Punktschätzer (konditional)

Konditional vs. Marginal

Warum unterscheiden sich Mixed Model und GEE?

Log-Link (Gamma-GLM für PPD):

	Mixed Model	GEE
Fragestellung	Effekt für *diesen* Patienten	Populationsdurchschnittlicher Effekt
exp(β)	Relat. Änderung *bei gleichem* Random Effect	Relat. Änderung *gemittelt über alle* RE
Schätzgleichung	E[Y|X, b]	E[Y|X] = E_b[E[Y|X, b]]

Bei log-link:

E[Y|X] = E_b[exp(Xβ + Zb)] = exp(Xβ) · E[exp(Zb)]

Der Term E[exp(Zb)] = exp(σ^2/2) ist *konstant*

→ **β_konditional ≈ β_marginal** (log-link ist „kollabierbar")

Implikation: Für PPD/CAL mit Gamma-GLM (log-link) sind die Unterschiede *gering*.

Konditional vs. Marginal

Bei Logit-Link (Parodontitis ja/nein): Nicht-Kollabierbarkeit!

	Mixed Logit	GEE Logit
Effektmaß	Konditionaler OR	Marginaler OR
Typische Größe	**Größer**	**Kleiner**
Warum?	OR ist mathematisch nicht kollabierbar	

Approximation (Zeger, Liang, Albert 1988):

$$\beta_{marginal} \approx \frac{\beta_{konditional}}{\sqrt{1 + c^2 \cdot \sigma_b^2}}$$

mit c ≈ 0.588 (Logit) → bei σ^2_b = 1: β_marg ≈ 0.77 · β_kond

Konditional vs. Marginal

Beispiel (Parodontitis)

	Log-OR	OR
Mixed Logit (konditional)	1.20	3.32
GEE Logit (marginal)	0.85	2.34

Beide sind „richtig" – sie beantworten verschiedene Fragen!

Wann welches Modell?

Entscheidungshilfe

Fragestellung	Modell	Beispiel
„Wie wirkt sich Karies auf die PPD *dieses Patienten* aus?"	Mixed Model (konditional)	Klinische Prognose, individuelle Therapieentscheidung
„Wie groß ist der Effekt von Karies auf PPD *in der Bevölkerung*?"	GEE (marginal)	Public-Health-Planung, Präventionsprogramme
„Ist der Effekt statistisch signifikant bei wenigen Praxen?"	Wild Cluster Bootstrap	Pilotstudien, kleine multizentrische Studien, kleines cluster-RCT

Empfehlungen:

- **Stetige Outcomes (PPD, CAL) + log-link:** Beide liefern *ähnliche* exp(β) → Wahl nach Fragestellung
- **Binäre Outcomes (Parodontitis ja/nein) + logit-link:** exp(β) *unterschiedlich* → Fragestellung *muss* vorab klar sein
- **Bei < 30 Clustern:** Immer Bootstrap oder Wild Cluster Bootstrap als Sensitivitätsanalyse

Kausale Inferenz: Grundlagen

Potential-Outcomes-Framework (Rubin, 1974)

Für jeden Zahn j in Patient i zum Zeitpunkt t:

$Y_{ijt}(1)$ = PPD, falls Karies (car_new = 1)

$Y_{ijt}(0)$ = PPD, falls keine Karies (car_new = 0)

Kausaler Effekt: $\tau_{ijt} = Y_{ijt}(1) - Y_{ijt}(0)$

→ Fundamentales Problem: Wir beobachten *nur ein* Potential Outcome! (Holland, 1988)

Identifikationsannahmen	Bedeutung	Herausforderung bei Clusterdaten
Exchangeability	$(Y(0),Y(1)) \perp A \mid X$	Unbeobachtete Confounder auf Praxis-/Patientenebene
Positivity	$0 < P(A=1 \mid X) < 1$	Manche Zahntypen/Patienten bekommen *selten*/*nie* Karies
Consistency	$Y = Y(a)$ wenn $A=a$	Karies ist nicht binär – Schweregrade!
SUTVA	No interference	**Verletzt!** Karies an Zahn j beeinflusst Zahn k

Kausale Inferenz: SUTVA und Clusterung

SUTVA-Verletzung ist das Kernproblem

SUTVA (Stable Unit Treatment Value Assumption):

Das Potential Outcome eines Zahnes hängt nicht davon ab, ob andere Zähne desselben Patienten Karies haben.

In der Realität:

Karies an Zahn 16 → Bakterienreservoir → ↑ Risiko an Zahn 17

Zahnverlust → Kippung → veränderte Belastung der Nachbarzähne

Systemische Entzündungsreaktion → alle Zähne betroffen

Lösungsansätze:

Strategie	Umsetzung
SUTVA auf Patientenebene	Exposition = Anteil kariöser Zähne (keine zahnspezifische Analyse)
Interference-Modelle	Spillover-Effekte explizit modellieren: „Karies am Nachbarzahn"
Partial identification	Bounds statt Punktschätzer unter milderen Annahmen
Mixed Models als Approximation	Patient-RE fängt „geteilte Anfälligkeit" partiell auf (aber kein Ersatz für kausale Identifikation!)

Take-Home Messages

1. Clusterung ernst nehmen

- In der oralen Epidemiologie sind Daten *oft* cluster-korreliert
- Selbst kleine ICCs → große Design-Effekte bei vielen Zähnen/Patient
- Naive Modelle → falsch-positive Ergebnisse

2. Methode zur Fragestellung wählen

- Mixed Model: subjektspezifische Prognose (konditional)
- GEE: Populationseffekte (marginal)
- Bei log-link (PPD, CAL): Unterschiede gering
- Bei logit-link (Parodontitis): Unterschiede substanziell

3. Clusteranzahl beachten

- $g < 30$ Praxen: Sandwich-SE verzerrt → Bootstrap verwenden
- Investiere in *mehr Cluster*, nicht in *größere Cluster*

4. Kausale Inferenz erfordert mehr als statistische Modelle

- SUTVA ist bei zahnspezifischen Analysen fragwürdig
- Mixed Models korrigieren SE, aber identifizieren keine kausalen Effekte
- Transparente Darstellung der Annahmen!

Vielen Dank für Ihre Aufmerksamkeit!

Code & Folien: github.com/BaumeisterS/Cluster_correlated