Universität Münster

Statistische Analyse cluster-korrelierter Daten

5. Mai 2026, DGoEV Jahrestagung

Univ.-Prof. Dr. Sebastian-Edgar Baumeister

Universität Münster

Übersicht

- Einleitung & Fragestellungen
- Was sind cluster-korrelierte Daten?
- Weshalb erfordern sie spezielle Verfahren?
- Statistische Methoden: Mixed Models, GEE, Bootstrap
- Die Rolle der Clusteranzahl
- Anwendung auf simulierte Daten
- Interpretation der Schätzer: konditional vs. marginal
- Kausale Inferenz bei cluster-korrelierten Daten

Motivation

Warum dieses Thema?

In der oralen Epidemiologie und Versorgungsforschung sind Daten häufig cluster-korreliert

Clusterebene	Beispiel
Zähne in Patienten	PPD-Messungen an 28 Zähnen
Taschen an Zähnen	Mehrere Messungen pro Zahn
Patienten in Praxen	Praxisbasierte Studien
Wiederholte Messungen	Kohorten

Leitfragen

Drei Leitfragen für diesen Impuls

1. Bias vs. Precision

Ignorieren von Clusterung → verzerrte *Standardfehler* (ggf. Punktschätzer bei nichtlinearen Modellen) → Zu enge Konfidenzintervalle, zu kleine p-Werte

2. Konditional vs. Marginal

Mixed Models und GEE beantworten *unterschiedliche Fragen* → Wann welches Effektmaß?

3. Kausalität

Clusterung hat Implikationen für kausale Identifikation → Welche Annahmen müssen gelten?

Was sind cluster-korrelierte Daten?

Beobachtungen sind cluster-korreliert, wenn Einheiten innerhalb eines Clusters einander ähnlicher sind als Einheiten aus anderen Clustern.

$Cor(Y_{ij}, Y_{ik}) > 0$ für j ≠ k innerhalb Cluster i

wobei:
i = Cluster (z.B. Patient)
j,k = Beobachtungen im Cluster (z.B. Zähne)

Intraklassenkorrelation (ICC):

$$\rho = \frac{\sigma^2_{Cluster}}{\sigma^2_{Cluster} + \sigma^2_{Residual}}$$

→ICC = 0: keine Korrelation innerhalb Cluster

→ICC = 1: perfekte Korrelation

Was sind cluster-korrelierte Daten?

Ebene 4: Zahnarztpraxis (g = 10–100 Praxen)

Ebene 3: Patient (n_j = 5–1000 pro Praxis)

Ebene 2: Zahn (28 Zähne pro Patient)

Ebene 1: Zeitpunkt (T Messungen pro Patient)

Varianzzerlegung (schematisch in linearem, additiven Random-Intercept-Modell):

$$\sigma^2_{Gesamt} = \sigma^2_{Praxis} + \sigma^2_{Patient} + \sigma^2_{Zahn} + \sigma^2_{Residual}$$

Typische ICCs in der Zahnmedizin (Masood 2014):

Clusterebene	
Praxis	0.02 – 0.08
Patient	0.15 – 0.40
Zahn	0.05 – 0.15

Quellen für Clusterung

Warum entsteht Clusterung in der oralen Epidemiologie und Versorgungsforschung

Biologisch:

- Genetische Disposition → alle Zähne eines Patienten betroffen
- Patientenbezogene Risikofaktoren (Rauchen, Diabetes, Immunsuppression) → Patientenebene
- Lokale Faktoren (Okklusion, Anatomie) → Zahnebene

Studiendesign:

- Longitudinale Messwiederholungen → serielle Korrelation
- Multizentrische Studien → Praxiseffekte (Diagnostik, Therapie)
- Cluster-randomisierte Studien → Randomisierung auf Praxenebene

Kreuzklassifikation:

- Zahn × Zeitpunkt (zwei gekreuzte Cluster innerhalb Patient)
- Patient × Praxis (bei Praxiswechsel)

Weshalb spezielle Verfahren?

Der Design-Effekt (DEFF)

$$DEFF = 1 + (\overline{m} - 1) \times ICC$$

wobei $\overline{m}$ = mittlere Clustergröße

Zahlenbeispiel:

$\overline{m}\ (\frac{Zähne}{Patient})$	ICC	DEFF	SE-Inflation (√DEFF)
28	0.05	2.35	1.53 ×
28	0.15	5.05	2.25 ×
28	0.30	9.10	3.02 ×

Konsequenz:

- Bei ICC = 0.15 ist der naive SE um Faktor 2.25 zu klein
- 95%-KI ist in Wirklichkeit ca. 2,25-mal so breit
- p-Werte sind dramatisch zu klein

Weshalb spezielle Verfahren?

Effektive Stichprobengröße:

$$n_{eff} = \frac{n}{DEFF}$$

Beispiel: 1.500 Patienten × 28 Zähne = 42.000 Beobachtungen

→ Bei DEFF = 5: $n_{eff} \approx 8.400$ *unabhängige* Beobachtungen

Weshalb spezielle Verfahren?

Drei Konsequenzen ignorierter Clusterung

1. Standardfehler zu klein

Typ-I-Fehler-Inflation

95%-KI hat tatsächliche Überdeckung von z. B. 70%

„Signifikante" Befunde, die keine sind

2. Modell-Inferenz ungültig

Likelihood-Ratio-Tests, AIC/BIC: falsch

Modellvergleiche nicht verlässlich

3. Effizienzeinbußen

Ungenutzte Information über die Korrelationsstruktur

Besonders bei unbalancierten Clustern: Mixed Models effizienter

Wichtig: Die *Punktschätzer* (β) bleiben unter milden Bedingungen erwartungstreu – das Problem sind die **Standardfehler** und damit die **Inferenz**.

Übersicht über Verfahren

Drei Auswertungsstrategien im Vergleich

	Mixed Models	GEE / Cluster-robust SE	Wild Cluster Bootstrap
Modellierung	Explizite Random Effects	Working Correlation	Resamplingbasiert
Effektmaß	Konditional (subjektspezifisch)	Marginal (populationsgemittelt)	Je nach Basismodell
SE-Korrektur	Modellbasiert	Sandwich-Schätzer	Empirisch
Kleine Cluster-N	Gut bei $g \geq 20$	Problematisch bei $g < 30$	Gut bei $g \geq 10$
Software	R: lme4, glmmTMB; Stata: meglm, mixed	R: gee, geepack; Stata: xtgee, vce(cluster)	R: boot, fwildclusterboot, wildboottestjlr; Stata: bootstrap, boottest

Mixed Models

Grundidee

Mixed Models zerlegen die Gesamtvarianz in feste und zufällige Effekte:

$$g\left(E\left[Y_{ij}|X, b_i\right]\right) = X_{ij}\beta + Z_{ij}b_i$$

β = feste Effekte (Populationsparameter)

b_i = zufällige Effekte ~ N(0,D)

→ Clusterspezifische Abweichungen vom Populationsmittel

g(.) = Link-Funktion (log, logit,…)

In unserem Beispiel (Gamma, log-link):

$$\log\left(E\left[PPD_{ijk}|X, b\right]\right) = \beta_1 car_{new} + \beta_2 age + \cdots + b_{Praxis,k} + b_{Patient,j}$$

$b_{Praxis,k}$ ~ N(0, σ^2_{Praxis})

$b_{Patient,j}$ ~ N(0, $\sigma^2_{Patient}$)

$\boldsymbol{\beta_1}$ **= konditionaler Effekt** = Effekt *bei gleichem* Random Effect

Mixed Models

Interpretation des konditionalen Effekts

$\exp(\beta_1)$ im Gamma-GLMM mit Log-Link:

„Für einen bestimmten Patienten in einer bestimmten Praxis ist die erwartete PPD bei neuer Karies um den Faktor $\exp(\beta_1)$ höher als ohne Karies.“

Vorteile:

- Natürliche Modellierung der Clusterstruktur
- ICC als Nebenprodukt
- Prädiktion auf Subjektebene möglich
- Effizient bei unbalancierten Daten

Nachteile:

- Verteilungsannahmen für Random Effects (Normalität)
- Rechenintensiv bei 3+ Ebenen und GLMMs
- Konditionaler Effekt ≠ Populationseffekt (bei nicht-kollabierbaren Links wie logit)

Mixed Models

Konvergenzprobleme bei GLMMs:

Laplace-Approximation statt Gauss-Hermite

Fallback: log-transformiertes lineares Mixed Model

GEE und Cluster-robuster SE

Generalized Estimating Equations (GEE)

Grundidee: Schätze den *marginalen* (populationsgemittelten) Effekt, ohne die Random-Effects-Verteilung zu spezifizieren.

Zwei Bausteine:

1. Arbeitende Korrelationsstruktur (working correlation):

- Exchangeable: $Cor\left(Y_{ij}, Y_{ik}\right)$ = α für alle $j \neq k$
- AR(1): $Cor\left(Y_{ij}, Y_{ik}\right) =$ α^|j−k|(longitudinal)
- Unstructured: alle Korrelationen frei

2. Sandwich-Schätzer (robust SE):

$$\widehat{\mathrm{Var}}\left(\hat{\beta}\right) = B^{-1}\left(\sum_{i=1}^{g} \hat{e}_i\, \hat{e}_i'\right) B^{-1}$$

→Konsistente SE *unabhängig* davon, ob die Arbeitskorrelation korrekt ist

→ Daher „robust"

GEE und Cluster-robuster SE

Generalized Estimating Equations (GEE)

Marginaler Effekt – Interpretation

$\exp(\beta_1)$ im GEE (Gamma, log-link):

„In der Population ist die erwartete PPD bei Zähnen mit neuer Karies um den Faktor $\exp(\beta_1)$ höher – gemittelt über alle Patienten und Praxen."

→ Gleicher Punktschätzer wie naives GLM (bei ‚Independent Working Correlation') → Nur die SE werden korrigiert → Clusterebene muss korrekt gewählt werden!

Zwei-Wege-Clusterung:

Was, wenn auf *beiden* Ebenen geclustert werden muss?

→ vce(cluster practice_id) konservativer (höhere Ebene) (Abadie et al. 2023)

→ Multi-way clustering (Cameron, Gelbach, Miller 2011)

Wild Cluster Bootstrap

Motivation

Sandwich-SE bei **wenigen Clustern (g < 30–50)** nach unten verzerrt:

- Asymptotische Theorie gilt für g → ∞
- Bei g = 10–15 Praxen: erhebliche Verzerrung

Wild Cluster Bootstrap (Cameron, Gelbach, Miller 2008):

Algorithmus:

1. Schätze Modell → erhalte Residuen $\hat{e}_{ij}$ und Schätzer $\hat{\beta}$
2. Für b = 1, …, B: a. Ziehe Rademacher-Gewichte $w_i \in \{-1, +1\}$ pro *Cluster*
   b. Bilde $Y_{ij}^* = X_{ij}\hat{\beta} + w_i \cdot \hat{e}_{ij}$ *c. Schätze Modell mit Y** → t*-Statistik
3. p-Wert: Anteil |t*| ≥ | $t_{beobachtet}$ |

Vorteil: Funktioniert bei wenigen Clustern (g ≥ 6–10)

Nachteil: Nur Hypothesentests, keine direkten KIs

Cluster Bootstrap (Praxenebene)

Klassischer Cluster-Bootstrap

Alternative bei wenigen Praxen:

Resample *ganze Praxen* mit Zurücklegen

→ Pairs cluster bootstrap ist bei sehr wenigen Clustern nicht immer überzeugend; häufig wird Wild Cluster Bootstrap bevorzugt

Vergleich der Bootstrap-Varianten:

	Pairs Cluster Bootstrap	Wild Cluster Bootstrap
Resamplingeinheit	Ganze Cluster	Residuen-Vorzeichen
Asymptotik	$g \to \infty$	$g \to \infty$, aber schneller
KIs	Direkt (Perzentile)	Nur p-Werte (ohne Erweiterung)
Empfehlung g	≥ 20	≥ 6–10

Rolle der Clusterzahl

Wie viele Cluster brauchen wir?

Für Sandwich-Schätzer (GEE/cluster-robust SE):

g(Cluster)	Bias des Sandwich-SE	Empfehlung
< 10	Stark nach unten verzerrt	⚠ Nicht verwenden
10–29	Moderate Verzerrung	Wild Cluster Bootstrap
30–49	Leichte Verzerrung	Akzeptabel mit Korrekturen
≥ 50	Vernachlässigbar	Zuverlässig

Korrekturen bei moderatem g:

- Mixed Models: Satterthwaite/Kenward-Roger
- Cluster-robuste Inferenz: Bell-McCaffrey, CR2/CR3, small-sample df, wild cluster bootstrap

Rolle der Clusterzahl

Effizienz und Information

Mixed Models: Information kommt aus *zwei Quellen*:

1. Between-Cluster-Variation (zwischen Praxen/Patienten)
2. Within-Cluster-Variation (innerhalb)

Effektiver Beitrag eines neuen Clusters vs. einer neuen Beobachtung im Cluster:

Bei hohem ICC:

- Ein *neuer Patient* bringt mehr Information als ein *zusätzlicher Zahn*
- Ein *neue Praxis* bringt mehr Information als ein *zusätzlicher Patient*

Faustformel für Power:

$$n_{eff} \approx \frac{g \cdot m}{1 + (m - 1) \cdot ICC}$$

→Bei ICC = 0.20 und m = 28 Zähnen: 28 Zähne ≈ **4.4 unabhängige** Beobachtungen pro Patient

→ Investiere in *mehr Cluster*, nicht in *größere Cluster*!

Simulationsstudie: Design

Simulierter Datensatz: Karies → Parodontitis

Datengenerierende Struktur:

- Drei-Ebenen-Clusterung:
  Praxis → Patient → Zahn × Zeit
- Zu Beginn: keine Karies, keine Parodontitis
- Diskretes Überlebensmodell für Karies-Onset
- PPD/CAL: Gamma-verteilt, beeinflusst durch Karies
- Zahnverlust: diskretes Hazard-Modell

Wahre Parameter (bekannt):

- β(Karies → PPD) = 0.60 mm
- σ_Praxis = 0.40, σ_Patient = 0.70, σ_Zahn = 0.30

Systematisch variiert:

Dimension	Werte
Zahnarztpraxen	10, 20, 30, 50, 100
Patienten / Praxis	5, 10, 20, 50, 100, 200, 500, 1000
Messwiederholungen	2, 3, 5, 8, 10

→ 16 Szenarien, Basisszenario: 30 Praxen, 50 Pat./Praxis, 5 ZP

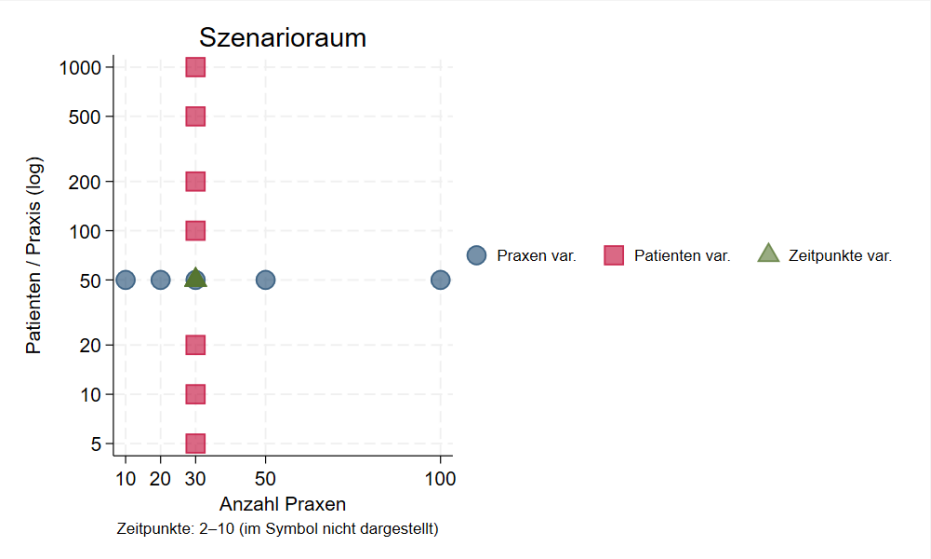

Simulationsstudie: Szenarien

Datensatzgrößen nach Szenario

Szenario	Praxen	Pat./Praxis	ZP	N Beobachtungen
Wenige Praxen	10	50	5	70.000
Basis	**30**	**50**	**5**	**210.000**
Viele Praxen	100	50	5	700.000
Kleine Cluster	30	5	5	21.000
Große Cluster	30	1000	5	4.200.000
Wenige ZP	30	50	2	84.000
Viele ZP	30	50	10	420.000

Exposition: car_new (neue Karies, zahnspezifisch)

Outcome: PPD (Probing Pocket Depth)

Simulationsstudie: Szenarien

Datensatzgrößen nach Szenario

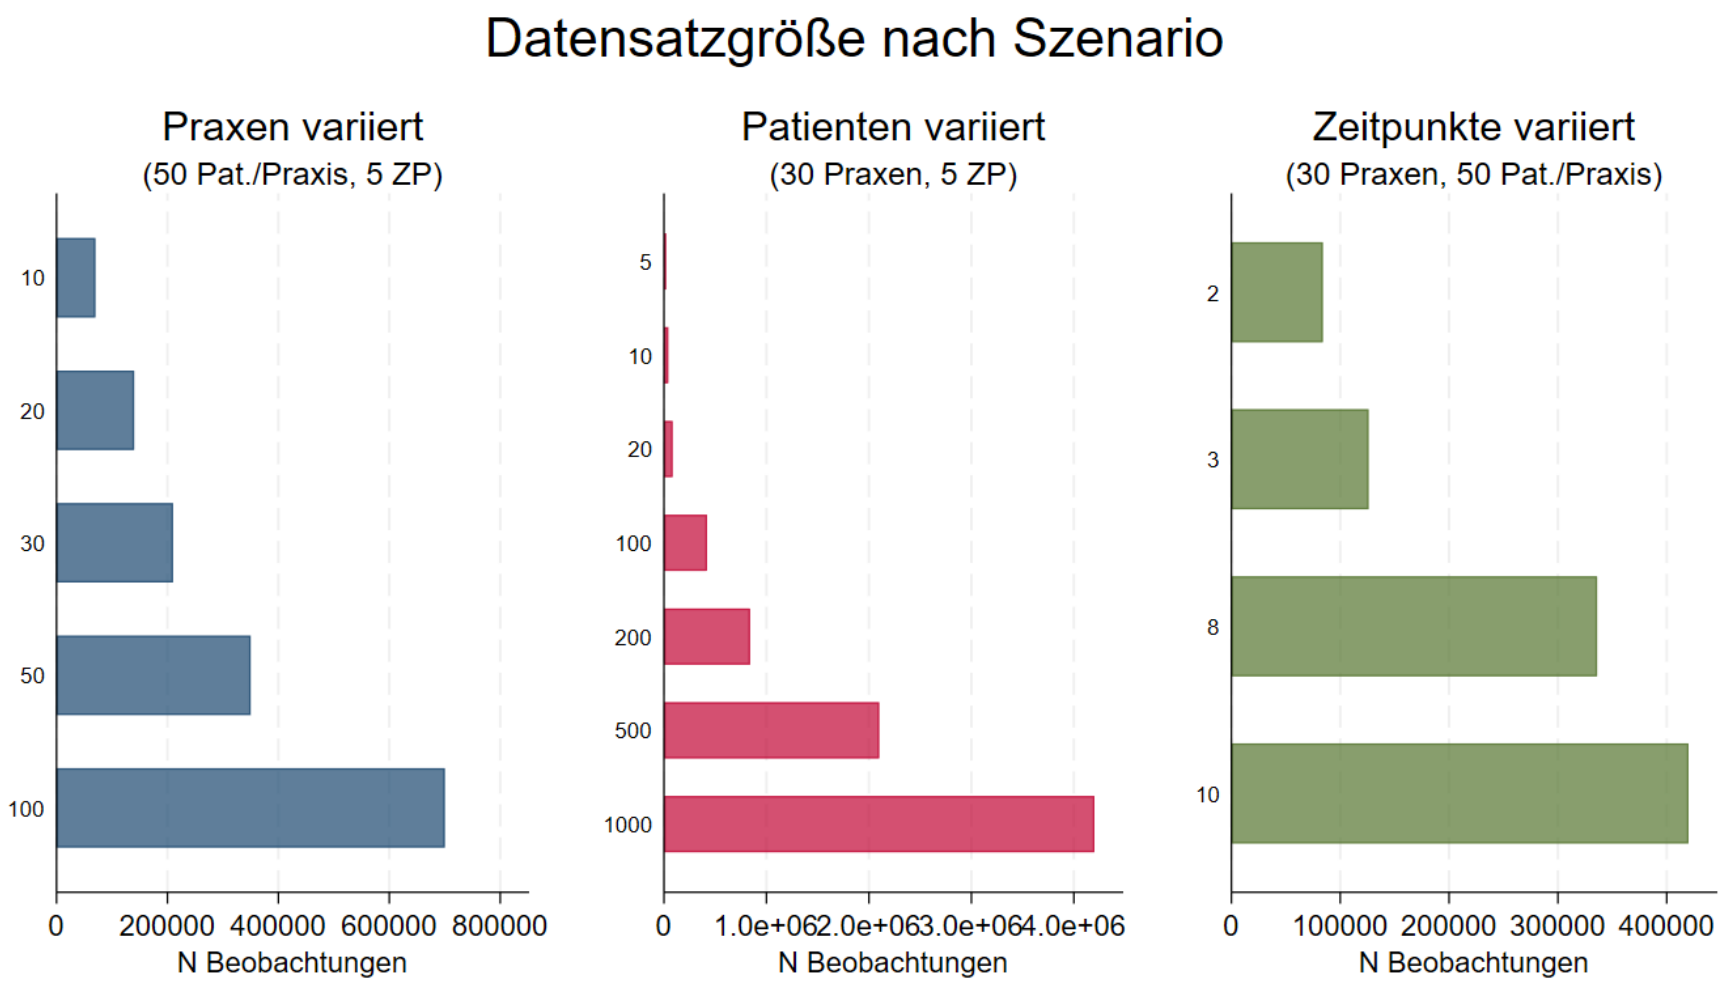

28 Zähne pro Patient

Ergebnisse: SE-Inflation

SE-Verhältnis (Methode / Naiv) nach Clustergröße

Zentrale Befunde:

	Pat./Praxis			
	5	**50**	**200**	**1000**
Cluster-Pat.	1.3	2.1	3.4	5.8
Cluster-Prax.	1.5	2.5	4.1	7.2
Mixed Model	1.4	2.3	3.8	6.5
GEE (robust)	1.3	2.2	3.6	6.1
Bootstrap	1.6	2.6	4.3	7.5

→ *Alle* Methoden zeigen SE > naives Modell

→ Inflation wächst mit Clustergröße (mehr Pat./Praxis)

→ Bootstrap am konservativsten (gut bei wenigen Praxen)

Ergebnisse: Gamma-GLM, log-link

exp(β) für car_new → PPD: Basisszenario

	exp(β)	95%-KI
Naiv (Clusterung ignoriert)	1.052	[1.038, 1.066]
Cluster-Pat.	1.052	[1.021, 1.084]
Cluster-Prax.	1.052	[1.014, 1.092]
Mixed Model	1.058	[1.022, 1.096]
GEE (exchangeable)	1.053	[1.020, 1.087]
Bootstrap	1.052	[1.011, 1.097]

→ Punktschätzer nahezu identisch (bei log-link!)

→ KI-Breite variiert um Faktor 2–3

→ Mixed Model: leicht höherer Punktschätzer (konditional)

Konditional vs. Marginal

Warum unterscheiden sich Mixed Model und GEE?

Log-Link (Gamma-GLM für PPD):

	Mixed Model	GEE
Fragestellung	Effekt für *diesen* Patienten	Populationsdurchschnittlicher Effekt
exp(β)	Relat. Änderung *bei gleichem* Random Effect	Relat. Änderung *gemittelt über alle* RE
Schätzgleichung	E[Y|X, b]	E[Y|X] = E_b [E[Y|X, b]]

Bei log-link und Random Intercept b_i :

$E[Y \mid X] = E_b[\exp(X\beta + \mathbf{b_i})] = \exp(X\beta) \cdot E[\exp(\mathbf{b_i})]$

Der Term $E[\exp(\mathbf{b_i})] = \exp({\sigma^2}_{\mathbf{b}}/2)$ ist konstant,

d.h. marginale Erwartung: $E[Y \mid X] = \underbrace{\exp({\sigma^2}_{\mathbf{b}}/2)}_{Konstante} \cdot \exp(X\beta) \rightarrow \beta_konditional = \beta_marginal.$

β sind identisch, nur der Intercept verschiebt sich um ${\sigma^2}_{\mathbf{b}}/2$.

Implikation: Für PPD/CAL mit Gamma-GLM (log-link) sind die Unterschiede *gering*.

Konditional vs. Marginal

Bei Logit-Link (Parodontitis ja/nein): Nicht-Kollabierbarkeit!

	Mixed Logit	GEE Logit
Effektmaß	Konditionaler OR	Marginaler OR
Typische Größe	**Größer**	**Kleiner**
Warum?	OR ist mathematisch nicht kollabierbar, da Logit-Funktion nicht-linear	

Nichtlineare Logit-Funktion:

$$E_b\left[\frac{\exp(X\beta + b)}{1 + \exp(X\beta + b)}\right] \neq \frac{\exp(X\beta + E_b[b])}{1 + \exp(X\beta + E_b[b])}$$

→ Erwartungswert der Funktion ist nicht die Funktion des Erwartungswerts

→ Die Marginalisierung über b_i kann *nicht* einfach in den Linkterm „gezogen" werden

Approximation (Zeger, Liang, Albert 1988): $\beta_{marginal} \approx \frac{\beta_{konditional}}{\sqrt{1+c^2 \cdot \sigma_b^2}}$, mit c ≈ 0.588 (Logit)

Konditional vs. Marginal

Beispiel (Parodontitis)

	Log-OR	OR
Mixed Logit (konditional)	1.20	3.32
GEE Logit (marginal)	0.85	2.34

Beide sind „richtig" – sie beantworten verschiedene Fragen!

Wann welches Modell?

Entscheidungshilfe

Fragestellung	Modell	Beispiel
„Wie wirkt sich Karies auf die PPD *dieses Patienten* aus?"	Mixed Model (konditional)	Klinische Prognose, individuelle Therapieentscheidung
„Wie groß ist der Effekt von Karies auf PPD *in der Bevölkerung*?"	GEE (marginal)	Public-Health-Planung, Präventionsprogramme
„Ist der Effekt statistisch signifikant bei wenigen Praxen?"	Wild Cluster Bootstrap	Pilotstudien, kleine multizentrische Studien, kleines cluster-RCT

Empfehlungen:

- **Stetige Outcomes (PPD, CAL) + log-link:** Beide liefern *ähnliche* exp(β) → Wahl nach Fragestellung
- **Binäre Outcomes (Parodontitis ja/nein) + logit-link:** exp(β) *unterschiedlich* → Fragestellung *muss* vorab klar sein
- **Bei < 30 Clustern:** Immer Bootstrap oder Wild Cluster Bootstrap als Sensitivitätsanalyse

Kausale Inferenz: Grundlagen

Potential Outcomes Framework (Rubin, 1974)

Für jeden Zahn j in Patient i zum Zeitpunkt t:

$Y_{ijt}(1)$ = PPD, falls Karies (car_new = 1)

$Y_{ijt}(0)$ = PPD, falls keine Karies (car_new = 0)

Kausaler Effekt: $\tau_{ijt} = Y_{ijt}(0) - Y_{ijt}(0)$

→ Fundamentales Problem: Wir beobachten *nur ein* Potential Outcome! (Holland, 1986)

Identifikationsannahmen	Bedeutung	Herausforderung bei Clusterdaten
Exchangeability	(Y(0),Y(1)) ⊥ A | X	Unbeobachtete Confounder auf Praxis-/Patientenebene
Positivity	0 < P(A=1|X) < 1	Manche Zahntypen/Patienten bekommen *selten*/*nie* Karies
Consistency (no Hidden Version of Treatment)	Y = Y(a) wenn A=a	Lokalisation, Schweregrade!
SUTVA: Spillover	No interference	Verletzt! Karies an Zahn j beeinflusst Zahn k

Kausale Inferenz: Spillover

„Das Potential Outcome eines Zahnes hängt nicht davon ab, ob andere Zähne desselben Patienten Karies haben“.

In der Realität:

Karies an Zahn 16 → Bakterienreservoir → ↑ Risiko an Zahn 17

Zahnverlust → Kippung → veränderte Belastung der Nachbarzähne

Lösungsansätze:

Strategie	Umsetzung
SUTVA auf Patientenebene	Exposition = Anteil kariöser Zähne (keine zahnspezifische Analyse)
Interference-Modelle	Spillover-Effekte explizit modellieren: „Karies am Nachbarzahn"
Partial identification	Bounds statt Punktschätzer unter milderen Annahmen
Mixed Models als Approximation	Patient-RE fängt „geteilte Anfälligkeit" partiell auf (aber kein Ersatz für kausale Identifikation!)

Take-Home Messages

1. Clusterung ernst nehmen

- In der oralen Epidemiologie sind Daten *oft* cluster-korreliert
- Selbst kleine ICCs → große Design-Effekte bei vielen Zähnen/Patient
- Naive Modelle → falsch-positive Ergebnisse

2. Methode zur Fragestellung wählen

- Mixed Model: subjektspezifische Prognose (konditional)
- GEE: Populationseffekte (marginal)
- Bei log-link (PPD, CAL): Unterschiede gering
- Bei logit-link (Parodontitis): Unterschiede substanziell

3. Clusteranzahl beachten

- $g < 30$ Praxen: Sandwich-SE verzerrt → Bootstrap verwenden
- Investiere in *mehr Cluster*, nicht in *größere Cluster*

4. Kausale Inferenz erfordert mehr als statistische Modelle

- SUTVA ist bei zahnspezifischen Analysen fragwürdig

Vielen Dank für Ihre Aufmerksamkeit!

Code & Folien: github.com/BaumeisterS/Cluster_correlated

Direkter vs. Spillover-Effekt

„Das Potential Outcome eines Zahnes hängt nicht davon ab, ob andere Zähne desselben Patienten Karies haben“.

In der Realität: Karies an Zahn 16 → Bakterienreservoir → ↑ Risiko an Zahn 17; Zahnverlust → Kippung → veränderte Belastung der Nachbarzähne

Direct Effect: Effekt der eigenen Karies auf die eigene PPD (bei konstantem Nachbar-Expositionsstatus).

Spillover Effect: Effekt der Karies an Nachbarzähnen auf die eigene PPD (bei konstantem eigenem Expositionsstatus)

Erweiterte Potential-Outcomes-Notation:

$Y_{ij}(\mathbf{a}_i) = Y_{ij}\left(a_{ij}, a_{i,-j}\right)$, wobei $a_{i,-j}$ der Behandlungsvektor aller *anderen* Zähne des Patienten i

Direkter vs. Spillover-Effekt

Setting

Zahn 16 (1. Molar oben rechts)

Eigene Exposition: A_{16} =Karies an Zahn 16 (ja/nein)

Spillover-Exposition: S_{16} =Karies am Nachbarzahn 15 oder 17 (ja/nein)

Outcome: Y_{16} =PPD an Zahn 16 (in mm)

Vier Potential Outcomes

	Nachbar gesund ($S = 0$)	**Nachbar kariös ($S = 1$)**
Zahn 16 gesund ($A = 0$)	$Y_{16}(0, 0) = 2.1\text{mm}$	$Y_{16}(0, 1) = 2.6\text{mm}$
Zahn 16 kariös ($A = 1$)	$Y_{16}(1, 0) = 3.0\text{mm}$	$Y_{16}(1, 1) = 3.8\text{mm}$

Effekt-Dekomposition (Hudgens & Halloran 2008)

Effekt	Definition	Berechnung	Interpretation
Direkter Effekt	$Y(1, s) - Y(0, s)$bei fixem s	$Y(1, 0) - Y(0, 0) = 3.0 - 2.1 = \mathbf{0.9\ mm}$	Effekt der *eigenen* Karies, wenn Nachbar gesund
Spillover Effekt	$Y(a, 1) - Y(a, 0)$bei fixem a	$Y(0, 1) - Y(0, 0) = 2.6 - 2.1 = \boldsymbol{0.5\ mm}$	Effekt der *Nachbar*-Karies, wenn Zahn 16 selbst gesund
Gesamteffekt	$Y(1, 1) - Y(0, 0)$	3.8 – 2.1 = 1.7 mm	Eigene + Nachbar-Karies
Interaktion	Gesamt-Direkt-Spillover	1.7 – 0.9 – 0.5 = 0.3 mm	Synergistischer Effekt beider Expositionen

Universität Münster

Literatur

Grundlagen: Cluster-korrelierte Daten & Design-Effekt: Kish L. Survey Sampling. New York: John Wiley & Sons; 1965. Masood M, Masood Y, Newton JT**.** The clustering effects of surfaces within the mouth and teeth within individuals. J Dent Res. 2014;93(1):84–88.

GEE & Sandwich-Schätzer: Liang KY, Zeger SL. Longitudinal data analysis using generalized linear models. Biometrika. 1986;73(1):13–22. Zeger SL, Liang KY, Albert PS. Models for longitudinal data: a generalized estimating equation approach. Biometrics. 1988;44(4):1049–1060.

Mixed Models: Bates D, Mächler M, Bolker B, Walker S. Fitting linear mixed-effects models using lme4. J Stat Softw. 2015;67(1):1–48. Brooks ME, Kristensen K, van Benthem KJ, et al. glmmTMB balances speed and flexibility among packages for zero-inflated generalized linear mixed modeling. R J. 2017;9(2):378–400.

Small-Sample-Korrekturen: Kenward MG, Roger JH. Small sample inference for fixed effects from restricted maximum likelihood. Biometrics. 1997;53(3):983–997. Bell RM, McCaffrey DF. Bias reduction in standard errors for linear regression with multi-stage samples. Surv Methodol. 2002;28(2):169–181.

Bootstrap-Verfahren: Cameron AC, Gelbach JB, Miller DL. Bootstrap-based improvements for inference with clustered errors. Rev Econ Stat. 2008;90(3):414–427. Roodman D, Nielsen MØ, MacKinnon JG, Webb MD. Fast and wild: Bootstrap inference in Stata using boottest. Stata J. 2019;19(1):4–60.

Multi-Way Clustering: Cameron AC, Gelbach JB, Miller DL. Robust inference with multiway clustering. J Bus Econ Stat. 2011;29(2):238–249. Abadie A, Athey S, Imbens GW, Wooldridge JM. When should you adjust standard errors for clustering? Q J Econ. 2023;138(1):1–35.

Literatur

Kausale Inferenz – Grundlagen: Rubin DB. Estimating causal effects of treatments in randomized and nonrandomized studies. J Educ Psychol. 1974;66(5):688–701. Holland PW. Statistics and causal inference. J Am Stat Assoc. 1986;81(396):945–960.

Kausale Inferenz - Interference & Spillover: Hudgens MG, Halloran ME. Toward causal inference with interference. J Am Stat Assoc. 2008;103(482):832–842. Tchetgen Tchetgen EJ, VanderWeele TJ. On causal inference in the presence of interference. Stat Methods Med Res. 2012;21(1):55–75. Aronow PM, Samii C. Estimating average causal effects under general interference, with application to a social network experiment. Ann Appl Stat. 2017;11(4):1912–1947. Sävje F, Aronow PM, Hudgens MG. Average treatment effects in the presence of unknown interference. Ann Stat. 2021;49(2):673–701.